

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE GOIÁS

BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

KAROLAYNE AMÁBILE BRITO BORGES, ANA LAURA MACHADO PEREIRA

**RECONHECIMENTO DE PRODUTOS POR CORRESPONDÊNCIA DE
CARACTERÍSTICAS LOCAIS**

RELATÓRIO TÉCNICO

ANÁPOLIS, 2025

1. INTRODUÇÃO

Este relatório descreve o desenvolvimento da segunda etapa do trabalho prático da disciplina, cujo objetivo foi construir um sistema capaz de reconhecer automaticamente diferentes produtos de uma linha de embalagens em bandeja, a partir de fotografias (resultados do T1), sem o uso de qualquer técnica de inteligência artificial ou aprendizado de máquina. O reconhecimento foi feito por meio de descritores locais de características, uma abordagem clássica de visão computacional que descreve pequenas regiões da imagem — como cantos, bordas e texturas — de forma que elas possam ser comparadas mesmo quando a imagem sofre variações de escala, rotação, iluminação ou perspectiva.

Para cada uma das sete classes de produto trabalhadas (Meio das Asas, Coxinhas das Asas, Filé de Peito, Coração, Moela, Filé de Coxas e Sobrecoxas com Pele e Coxas e Sobrecoxas), foi escolhida manualmente uma pequena região da embalagem — o nome do produto impresso no rótulo — para servir como imagem de referência, chamada de template. Para cada segmento recortado automaticamente na primeira etapa do projeto, se é comparada com todos os sete templates, e o sistema decide qual produto está presente com base em qual template obteve a melhor correspondência de pontos de interesse.

1.2 CÓDIGO FONTE E TEMPLATES

Esta seção reúne todos os artefatos necessários para a execução do projeto (código-fonte, imagens de referência e conjunto de dados de entrada) e descreve o passo a passo para preparar o ambiente antes da execução.

Código-fonte: notebook completo no Google Colab com a implementação do reconhecimento via SIFT. Disponível em:

<https://colab.research.google.com/drive/1Mdk11uR3lice8v3nEALw27R20JGxsDQU?usp=sharing>.

Templates: conjunto com as 7 imagens-template (uma para cada classe de produto).

Disponível em:

<https://drive.google.com/drive/folders/1Fyl80zqfyN3DyZumCqn9P8RsOe7h7OJM?usp=sharing>.

Imagens de Entrada: recortes gerados na primeira parte do trabalho (T1), limitados apenas às classes de interesse (bandejas). Caso não os tenha localmente, utilize este link. Disponível em: <https://drive.google.com/drive/folders/1QyfigNMXRSCo2-gZuCEcGD3wCC9AJSOH?usp=sharing>.

2. TABELA DOS TEMPLATES

Para representar cada classe de produto, foi selecionada, entre as cerca de 50 imagens disponíveis por classe, uma única fotografia que apresentasse boa nitidez e pouca deformação da embalagem. A partir dessa fotografia, recortou-se manualmente, em um editor de imagens, a região do rótulo onde o nome do produto está impresso. A tabela a seguir apresenta os sete templates utilizados, com o nome do arquivo correspondente e a justificativa da escolha.

PRODUTO/CLASSE	IMAGEM UTILIZADA	JUSTIFICATIVA
CORAÇÃO	 <i>coracao.png</i>	Texto e logotipo bem preservados, com boa nitidez e contraste em relação ao fundo da embalagem, o que favorece a extração de um número consistente de pontos-chave SIFT.
COXAS E SOBRECoxas	 <i>coxa_sobrecoxa.png</i>	Texto e logotipo bem preservados, com boa nitidez e contraste em relação ao fundo da embalagem, o que favorece a extração de um

PRODUTO/CLASSE	IMAGEM UTILIZADA	JUSTIFICATIVA
		número consistente de pontos-chave SIFT.
COXINHAS DAS ASAS	 <i>coxinha_da_asa.png</i>	Texto e logotipo bem preservados, com boa nitidez e contraste em relação ao fundo da embalagem, o que favorece a extração de um número consistente de pontos-chave SIFT.
FILÉ DE COXAS E SOBRECOXAS COM PELE	 <i>file_coxa_sobrecoxa_com_pele.png</i>	Texto e logotipo bem preservados, com boa nitidez e contraste em relação ao fundo da embalagem, o que favorece a extração de um número consistente de pontos-chave SIFT.
FILÉ DE PEITO	 <i>file_peito_congelado.png</i>	Texto e logotipo bem preservados, com boa nitidez e contraste em relação ao fundo da embalagem, o que favorece a extração de um número consistente de pontos-chave SIFT.
MEIO DAS ASAS		Texto e logotipo bem preservados, com boa

PRODUTO/CLASSE	IMAGEM UTILIZADA	JUSTIFICATIVA
	<i>meio_da_asa_congelado.png</i>	nitidez e contraste em relação ao fundo da embalagem, o que favorece a extração de um número consistente de pontos-chave SIFT.
MOELA	 <i>moela.jpg</i>	Texto e logotipo bem preservados, com boa nitidez e contraste em relação ao fundo da embalagem, o que favorece a extração de um número consistente de pontos-chave SIFT.

3. PARÂMETROS DO ALGORITMO

O algoritmo de reconhecimento foi implementado com o descritor SIFT (Scale-Invariant Feature Transform), escolhido por sua robustez a variações de escala, rotação e iluminação, características esperadas nas fotografias das embalagens, que não seguem um enquadramento perfeitamente padronizado. Para cada imagem, o SIFT detecta pontos de interesse e gera, para cada um deles, um vetor descritor de 128 dimensões que codifica a distribuição local de gradientes ao redor do ponto.

A correspondência entre os pontos-chave do template e os do segmento avaliado é feita com um BFMatcher (Brute-Force Matcher) usando distância euclidiana (NORM_L2), seguido do teste da razão de Lowe: para cada ponto do template, são recuperados os dois vizinhos mais próximos no conjunto de descritores do segmento, e a correspondência só é aceita como "boa" se a distância do vizinho mais próximo for inferior a 0,72 vezes a distância do segundo vizinho

mais próximo, o que permite descartar correspondências ambíguas, que ocorreriam, por exemplo, em regiões repetitivas da imagem.

As correspondências que passam no teste da razão ainda são submetidas a uma verificação geométrica usando RANSAC. O algoritmo tenta ajustar uma homografia entre os pontos do template e os do segmento, com um limiar de erro de reprojeção de 5 pixels. Somente as correspondências consistentes com essa transformação geométrica (inliers) são contadas como válidas, o que efetivamente reduz falsos positivos.

O placar final de cada comparação template–segmento é calculado como a porcentagem de pontos do template que encontraram uma correspondência geometricamente válida no segmento ($100 \times \text{inliers} / \text{número de pontos do template}$). Um segmento é classificado com o produto do template que obteve o maior placar, desde que esse placar ultrapasse o limiar mínimo de decisão (LIMIAR); caso contrário, o segmento é marcado como "não detectado" em vez de arriscar uma classificação errada. A tabela a seguir resume os valores finais de todos os parâmetros utilizados.

PARÂMETRO	VALOR FINAL
Descritor	SIFT
SIFT nfeatures	0
SIFT nOctaveLayers	3
SIFT contrastThreshold	0.04
SIFT edgeThreshold	10
SIFT sigma	1.6
Matcher	BFMatcher (NORM_L2) + razão de Lowe
Razão de Lowe (RATIO)	0.72
Mínimo de good matches (MIN_GOOD)	8
RANSAC reproj. threshold (px)	5.0

PARÂMETRO	VALOR FINAL
Score	$100 \times \text{inliers} / \text{n}^\circ \text{ de pontos do template}$
LIMIAR ótimo (%)	5.25

3.1 HISTÓRICO DE CALIBRAÇÃO

O único parâmetro efetivamente calibrado neste trabalho foi o limiar de decisão (LIMIAR), isto é, a porcentagem mínima de correspondências válidas exigida para que o sistema aceite uma classificação. Para encontrá-lo, o placar de todas as 350 imagens contra os sete templates foi calculado uma única vez, e então uma varredura de limiares entre 1,00% e 8,00%, em passos de 0,25 ponto percentual, foi aplicada sobre esses placares já calculados.

Para cada limiar testado, contabilizou-se o número de acertos, de segmentos não detectados e de falsos positivos, e o limiar escolhido foi aquele que maximizou a função objetivo $\text{acertos} - 2 \times \text{falsos_positivos}$ (o peso 2 atribuído aos falsos positivos reflete a exigência do enunciado do trabalho de que o sistema priorize a confiabilidade das classificações, aceitando reduzir a quantidade de produtos identificados em troca de cometer menos erros de identificação incorreta).

É possível observar na tabela abaixo que, em limiares muito baixos (1,00% a 2,00%), a acurácia bruta chega a ser numericamente mais alta (em torno de 80%), mas às custas de um número elevado de falsos positivos (65 a 67). À medida que o limiar sobe, o número de falsos positivos cai de forma consistente, e o limiar de 5,25% foi o ponto em que a função objetivo atingiu seu valor máximo, equilibrando 256 acertos com apenas 44 falsos positivos.

Limiar (%)	Acertos	Não detectado	Falso Positivos	Acurácia %
1.00	281	2	67	80.3
1.25	281	3	66	80.3

Limiar (%)	Acertos	Não detectado	Falso Positivos	Acurácia %
1.50	281	4	65	80.3
1.75	280	5	65	80.0
2.00	280	5	65	80.0
2.25	279	8	63	79.7
2.50	279	8	63	79.7
2.75	279	8	63	79.7
3.00	278	9	63	79.4
3.25	277	11	62	79.1
3.50	276	12	62	78.9
3.75	275	14	61	78.6
4.00	274	17	59	78.3
4.25	273	18	59	78.0
4.50	270	29	51	77.1
4.75	265	36	49	75.7
5.00	262	41	47	74.9
5.25	256	50	44	73.1
5.50	253	53	44	72.3
5.75	248	61	41	70.9
6.00	243	66	41	69.4
6.25	234	80	36	66.9
6.50	222	92	36	63.4

Limiar (%)	Acertos	Não detectado	Falso Positivos	Acurácia %
6.75	215	104	31	61.4
7.00	209	112	29	59.7
7.25	195	132	23	55.7
7.50	185	145	20	52.9
7.75	179	152	19	51.1
8.00	172	160	18	49.1

Método: cada imagem é comparada com os sete templates; o produto identificado é o de maior placar (argmax), e essa classificação só é confirmada se o placar for maior ou igual ao LIMIAR — caso contrário, o resultado é "não detectado". O limiar ótimo foi obtido maximizando acertos – 2×falsos positivos na varredura acima, destacada na linha correspondente a 5,25%.

4. RESULTADOS

Com o limiar de 5,25% fixado, o sistema foi aplicado às 350 imagens do conjunto de avaliação (50 imagens por classe), produzindo os resultados consolidados na tabela abaixo.

Produto	Total de imagens	Acertos	Não detectado	Falso Positivos
Meio das Asas	50	37	4	9
Coxinhas das Asas	50	37	6	7
File de Peito	50	42	6	2
Coracao	50	45	4	1
Moela	50	33	15	2
File de Coxas e Sobrecoxas com Pele	50	27	4	19

Produto	Total de imagens	Acertos	Não detectado	Falso Positivos
Coxas e Sobrecoxas	50	35	11	4
Total	350	256	50	44

Acurácia global: 73,1% · Total de falsos positivos: 44 · Não detectados: 50

6. CONCLUSÃO

O trabalho demonstrou que é possível construir um classificador de produtos funcional utilizando exclusivamente técnicas clássicas de visão computacional, sem qualquer etapa de treinamento supervisionado. A combinação de SIFT, teste da razão de Lowe e verificação geométrica por RANSAC mostrou-se robusta o suficiente para diferenciar a maioria das sete classes de produto com base em uma única imagem de referência por classe.

A calibração cuidadosa do limiar de decisão foi determinante para o resultado final: limiares mais baixos geravam mais falsos positivos, enquanto o valor de 5,25% conseguiu um equilíbrio adequado entre confiabilidade e cobertura.